

Geração de Classes Estatísticas e Medição de Distorção em Séries Temporais

Wendell Christian Calixto Pinto, 2026103140

ELT 451 – Inteligência Computacional

Departamento de Engenharia Elétrica, Universidade Federal de São João del-Rei, São João del-Rei - MG

E-mail: wendellchristian651@aluno.ufsj.edu.br

Resumo- Este relatório apresenta a implementação computacional de geradores de dados bidimensionais baseados em distribuições gaussiana e uniforme, fundamentais para simulações em inteligência computacional. Adicionalmente, desenvolveu-se uma rotina para calcular a distorção em decibéis (dB) entre duas séries temporais, estimando o valor esperado por meio da média aritmética. Os algoritmos foram desenvolvidos na linguagem Python, utilizando as bibliotecas NumPy e Matplotlib para processamento e visualização. A análise gráfica confirmou o comportamento estatístico esperado para ambas as classes, validando as formulações matemáticas aplicadas.

INTRODUÇÃO

A modelagem estatística e a geração de dados sintéticos são etapas cruciais no teste e validação de algoritmos de inteligência computacional. Compreender como diferentes distribuições espaciais se comportam permite avaliar a robustez de classificadores e redes neurais. Duas das distribuições mais comuns e úteis nesse contexto são a Normal (Gaussiana) e a Uniforme.

A distribuição gaussiana é caracterizada por sua concentração de dados em torno de uma média, decaindo suavemente conforme a variância. Já a distribuição uniforme não possui tendência central, atribuindo probabilidade igual a todos os pontos contidos em um determinado intervalo.

Além da geração espacial, a avaliação de sinais ou séries temporais processadas requer métricas precisas de erro. A comparação entre um sinal original e um sinal distorcido é fundamental em telecomunicações e processamento digital.

A Objetivos

O objetivo geral deste trabalho é consolidar a manipulação de matrizes e funções matemáticas básicas aplicadas à estatística espacial e processamento de sinais.

Os objetivos específicos compreendem:

- Implementar uma rotina para geração e visualização de classes 2D com distribuição gaussiana e uniforme.
- Desenvolver uma função matemática para medir a distorção (em dB) entre duas séries temporais distintas.

MATERIAIS E MÉTODOS

O experimento foi conduzido por meio de simulação computacional utilizando a linguagem Python, com o auxílio das bibliotecas *NumPy* para operações algébricas e estatísticas, e *Matplotlib* para a plotagem dos dados.

Para a geração da classe Gaussiana, utilizou-se a função nativa de geração de números pseudoaleatórios, inserindo como parâmetros a média (μ) e o desvio padrão (σ). Como os dados de entrada fornecidos consistiam na variância (σ^2), foi necessário extrair a raiz quadrada deste valor para alimentar a função geradora bidimensional (eixos X e Y).

Para a classe Uniforme, estipulou-se uma margem fixa a partir dos mesmos valores de média utilizados na classe gaussiana. O intervalo de sorteio foi definido como $[\mu - \text{margem}, \mu + \text{margem}]$, garantindo a criação de um bloco de pontos contido dentro desses limites.

No que tange à segunda atividade, a medição da distorção entre duas séries temporais $x(k)$ e $y(k)$ foi calculada utilizando uma razão de potências em escala logarítmica. A Equação (1) descreve a métrica adotada:

$$d_{xy} = 10 \log_{10} \left(\frac{E[(x(k) - y(k))^2]}{E[x^2(k)]} \right) \quad (1)$$

onde o operador $E[\dots]$, que representa o Valor Esperado, foi computacionalmente estimado através da média aritmética das matrizes resultantes. O numerador exprime a energia do erro quadrático, enquanto o denominador exprime a potência média da série de referência $x(k)$.

RESULTADOS E DISCUSSÕES

A partir do código implementado, foram geradas 100 amostras para cada classe estatística. Optou-se por utilizar médias idênticas para facilitar a sobreposição gráfica e observar a natureza da dispersão.

Como pode ser observado na Figura 1, a classe Gaussiana apresenta uma densidade elevada na intersecção das médias (centro do plano), espalhando-se de forma gradativamente mais rarefeita nas bordas. Em contrapartida, a classe Uniforme ocupa rigidamente o espaço quadrado delimitado pelo algoritmo de margens, sem apresentar qualquer viés central.

Em relação à rotina de distorção temporal, a métrica foi validada calculando-se o erro entre duas séries defasadas geradas




Figura 1: Dispersão bidimensional das classes Gaussiana e Uniforme geradas computacionalmente.

artificialmente (uma onda seno e uma onda cosseno) sobre o mesmo vetor de tempo. A conversão final em decibéis permitiu transformar a variação da potência do erro entre os dois sinais em uma escala padronizada e interpretável.

CONCLUSÕES

A realização deste trabalho prático permitiu transpor formulações estatísticas teóricas para o ambiente computacional. Ficou evidente a diferença estrutural entre distribuições com foco em tendências centrais e distribuições equiprováveis num espaço confinado.

Ademais, a implementação matemática da distorção temporal em decibéis comprovou que, ao lidar com matrizes ou listas de dados, a estimativa do valor esperado através da média aritmética é uma abordagem rápida e computacionalmente barata para avaliar a fidelidade de processamento entre um sinal original e um ruidoso/distorcido. As lógicas desenvolvidas poderão ser embarcadas futuramente em redes neurais e algoritmos de filtragem de sinais como métricas de penalidade ou erro.

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] I. N. da Silva, D. H. Spatti, e R. A. Flauzino, *Redes Neurais Artificiais para engenharia e ciências aplicadas*. São Paulo: Artliber, 2010.
- [2] UFV, *Roteiro P3 - ELT 451 Inteligência Computacional: Neurônio de McCulloch-Pitts*, Viçosa, MG.