

Implementação e Análise do Neurônio de McCulloch-Pitts Aplicado a Portas Lógicas e Análise de Crédito

Wendell Christian Calixto Pinto, 2026103140

ELT 451 – Inteligência Computacional

Departamento de Engenharia Elétrica, Universidade Federal de São João del-Rei, São João del-Rei - MG

E-mail: wendellchristian651@aluno.ufsj.edu.br

Resumo- Este trabalho apresenta a implementação computacional do modelo de neurônio de McCulloch-Pitts e sua aplicação na resolução de problemas linearmente separáveis. Desenvolvido na linguagem Python, o algoritmo simulou com êxito as portas lógicas OR e NAND. No entanto, demonstrou sua restrição teórica ao falhar na porta não-linear XOR. O modelo também foi testado em uma tabela de análise de crédito, evidenciando a limitação do ajuste manual em problemas multidimensionais complexos que requerem múltiplas camadas.

INTRODUÇÃO

As Redes Neurais Artificiais (RNA) são estruturas matemáticas capazes de resolver problemas de classificação de padrões e modelagem dinâmica de sistemas [1]. O funcionamento destas redes é inspirado no neurônio biológico.

Warren McCulloch e Walter Pitts propuseram em 1943 um modelo matemático de um neurônio [2]. Para representar os dendritos, o modelo utiliza n terminais de entrada de informações $x_1, x_2, \dots, x_n$. Cada entrada é multiplicada por um coeficiente ponderador que visa à simulação das sinapses. De forma análoga à biologia, a ativação só ocorre quando a soma ponderada dos sinais ultrapassa um limiar pré-definido, resultando em um disparo Booleano através de uma função de ativação.

A saída y do neurônio de McCulloch-Pitts é dada pela Equação (1):

$$y = \varphi \left(\sum_{i=1}^n x_i w_i + \theta_k \right) \quad (1)$$

onde n é o número de entradas, w_i é o peso associado, θ_k é o limiar de ativação (bias) e $\varphi(\cdot)$ é a função de ativação. Uma restrição existente nesse modelo é que ele só consegue resolver, com erro zero, problemas linearmente separáveis [1].

MATERIAIS E MÉTODOS

O experimento foi realizado na linguagem Python, utilizando a biblioteca NumPy para otimização matemática. A implementação consistiu na elaboração da função `neuronio`, que recebe os vetores de entrada, de pesos e o valor do *bias*.

O cálculo da junção de somatório foi programado através do produto escalar `np.dot(entrada, peso)`, somado ao *bias*. A

função de ativação adotada foi a função degrau, implementada nativamente através de um desvio condicional (`if/else`): caso o resultado da soma seja maior ou igual a zero, a função retorna 1; caso contrário, retorna 0. Essa estrutura foi parametrizada manualmente para emular funções lógicas de dois bits e simular as decisões de um especialista em análise de crédito [2].

RESULTADOS E DISCUSSÃO

Para emular a porta lógica OR, os pesos sinápticos foram ajustados para $w = [1, 1]$ e o *bias* para -1 . O neurônio disparou corretamente a saída 1 para as entradas $(0, 1)$, $(1, 0)$ e $(1, 1)$, e manteve a saída 0 para $(0, 0)$.

Para a função NAND, utilizou-se pesos negativos. Com $w = [-1, -1]$ e *bias* de 1, o neurônio ativou a saída 1 para as combinações $(0, 0)$, $(0, 1)$ e $(1, 0)$. A saída foi corretamente mantida em 0 apenas quando ambas as entradas foram 1 $(1, 1)$, demonstrando que o modelo atende perfeitamente a problemas onde os padrões podem ser separados por meio de uma reta.

Contudo, na emulação da porta XOR, não foi possível encontrar uma reta de separação funcional. Isso ocorre devido à restrição do modelo, que não resolve problemas não-linearmente separáveis, exigindo redes com múltiplas camadas para equacionar os padrões cruzados do XOR [1].

No teste da análise de crédito, o modelo precisou avaliar sete variáveis: Idade, Sexo, Casa, Carro, Casado(a), Nº filhos e Renda. O ajuste de um único neurônio artificial para simular perfeitamente as decisões do especialista provou-se ineficaz. A alta dimensionalidade dos dados e as correlações intrínsecas (onde a combinação de variáveis altera o peso decisivo de outra) configuram um hiperplano não-linear de decisão, impossibilitando a separação das aprovações por meio de uma única estrutura isolada de limiar estático.

Por consequência direta dessa limitação matemática e da incapacidade de se obter um neurônio devidamente ajustado sem erro de classificação, a etapa de aplicação do modelo para analisar o crédito de colegas de turma não pôde ser executada. A ausência de convergência linear inviabilizou o uso confiável da rede para inferência em novos dados reais dentro do escopo da arquitetura proposta.

CONCLUSÕES

A prática permitiu compreender a dinâmica de operação e os conceitos do neurônio de McCulloch-Pitts. Os resultados confirmaram a eficácia do modelo em mapear a reta de separação de padrões lineares nas portas lógicas OR e NAND. A ocorrência de impossibilidades na porta XOR e na classificação multidimensional do banco de análise de crédito comprovou na prática a principal teoria associada ao modelo: sua restrição absoluta a problemas linearmente separáveis. Conclui-se que arquiteturas

multicamadas são essenciais para dados e decisões do mundo real.

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] I. N. da Silva, D. H. Spatti, e R. A. Flauzino, *Redes Neurais Artificiais para engenharia e ciências aplicadas*. São Paulo: Artliber, 2010.
- [2] UFV, *Roteiro P3 - ELT 451 Inteligência Computacional: Neurônio de McCulloch-Pitts*, Viçosa, MG.